

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
“КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ
імені ІГОРЯ СІКОРСЬКОГО”

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

«На правах рукопису»

УДК 519.854.3

«До захисту допущено»

Завідувач кафедри

М. В. Грайворонський

(підпис)

“ ”

(ініціали, прізвище)

2020 р.

Дипломна робота

на здобуття ступеня бакалавра

**за освітньо-науковою програмою “Математичні методи комп’ютерного
моделювання”**

зі спеціальності 113 «Прикладна математика»

на тему: «Модель побудови безхмарних композитів супутникових знімків»

Виконав: студент 4 курсу групи ФІ-61

Шило Максим Костянтинович

Науковий керівник: д.т.н., проф., Шелестов Андрій Юрійович

Рецензент: к.т.н., с.н.с., Яйлимов Богдан Ялкапович

(підпис)

(підпис)

(підпис)

Засвідчую, що у цій дипломній роботі немає
запозичень з праць інших авторів без відпо-
відних посилань.

Студент _____

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
“КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ
імені ІГОРЯ СІКОРСЬКОГО”

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

Рівень вищої освіти – перший (бакалаврський)

Спеціальність – 113 Прикладна математика

Освітньо-наукова програма: «Математичні методи комп’ютерного моделювання»

ЗАТВЕРДЖУЮ

Завідувач кафедри

М. В. Грайворонський

(підпис)

(ініціали, прізвище)

“ _____ ”

_____ 2020 р.

ЗАВДАННЯ

на дипломну роботу студенту

Шилу Максиму Костянтиновичу

1. Тема дипломної роботи «Модель побудови безхмарних композитів супутникових знімків»
науковий керівник дипломної роботи Шелестов Андрій Юрійович,
доктор технічних наук,
затверджені наказом по університету від «_____» _____ 2020р. № _____
2. Термін подання студентом дипломної роботи _____
3. Об’єкт дослідження — супутникові композити.
4. Предмет дослідження — методи машинного навчання.
5. Перелік завдань, які потрібно розробити:
 - а) дослідити маски хмарності;
 - б) побудувати модель вилучення хмар;
 - в) відновити колірний простір для з’єднаних композитів;

- г) розробити демонстраційне програмне забезпечення.
6. Орієнтовний перелік ілюстративного матеріалу: 10 слайдів.
7. Орієнтовний перелік публікацій: 1 публікація.
8. Дата видачі завдання _____

Календарний план

№ з/п	Етапи	Термін виконання	Примітка
1.	Ознайомлення з літературою	05.10.2018–19.08.2019	
2.	Розробка в Open Data Cube	19.08.2019–20.02.2020	
3.	Аналіз даних	20.02.2020–10.03.2020	
4.	Розробка моделі вилучення хмар	10.03.2020–10.05.2020	
5.	Оцінка точності	10.05.2020–25.05.2020	

Студент _____

М. К. Шило

Науковий керівник _____

А. Ю. Шелестов

ABSTRACT

The thesis contains 59 pages, 21 figures and 17 references.

The aim is to develop a model for obtaining cloud-free composites of satellite images. Sentinel-2 data from the Copernicus Open Access Hub and the Kyiv region are studied. Cloud masks, image-combination methods, and regression models for colour transfer between incomplete neighbouring regions are investigated. The best quality among the tested models was obtained with a multilayer perceptron.

Keywords: CLOUD-FREE COMPOSITE, CLOUD MASK, PIXEL, SPECTRAL CHANNEL, OPEN DATA CUBE, SENTINEL-2, SATELLITE DATA

РЕФЕРАТ

Дипломна робота містить 59 сторінок, 21 ілюстрацій і бібліографію з 17 найменування.

Метою роботи є розробка моделі отримання безхмарних композитів супутникових знімків. Досліджено маски хмарності для території Київської області та запропоновано їх уточнення морфологічним оператором розширення. Порівняно методи комбінування знімків і виконано перенесення колірного простору між сусідніми регіонами на неповних даних. Найкращу якість показав багат шаровий перцептрон.

Ключові слова: КОМПОЗИТ, МАСКА, ПІКСЕЛЬ, КАНАЛ, OPEN DATA CUBE, SENTINEL-2, СУПУТНИКОВІ ДАНІ

ЗМІСТ

Перелік умовних позначень, символів, одиниць, скорочень і термінів	8
Вступ	9
1 Сучасний стан задачі побудови безхмарних знімків	11
1.1 Descartes Labs	11
1.2 EOxCloudless	12
Висновки до розділу 1	14
2 Огляд Open Data Cube та супутникових даних	15
2.1 Open Data Cube	15
2.2 Супутник Sentinel-2	17
Висновки до розділу 2	19
3 Уточнення маски хмар	20
3.1 Маска хмарності	20
3.2 Недоліки маски хмар від COAH	21
3.3 Розширення маски хмар	22
Висновки до розділу 3	26
4 Алгоритм вилучення хмарних пікселів	27
4.1 Побудова безхмарного композиту	27
4.2 Медіана за каналами	31
Висновки до розділу 4	33
5 Модель відновлення супутникових даних	34
5.1 Color Transfer	35
5.2 Лінійна регресія	36
5.3 Баєсова регресія	38
5.4 Поліноміальна регресія	39
5.5 Багатошаровий перцептрон	40
5.6 Випадковий ліс	41
Висновки до розділу 5	43

6	Оцінка точності маски хмар та композитингу	44
6.1	Результати покращення маски хмар	45
	Висновки до розділу 6	47
7	Результати регресійних моделей	48
7.1	Навчальні дані	48
7.2	Результати	50
7.2.1	Лінійна та Поліноміальна регресії	51
7.2.2	Баєсова регресія	52
7.2.3	Ансамблеві та нейромережеві підходи	54
	Висновки до розділу 7	56
	Висновки	57
	Перелік посилань	58

ПЕРЕЛІК УМОВНИХ ПОЗНАЧЕНЬ, СИМВОЛІВ, ОДИНИЦЬ, СКОРОЧЕНЬ І ТЕРМІНІВ

QGIS — Quantum Geographic Information System;

OSGeo — Open Source Geospatial Foundation;

ODC — Open Data Cube;

COAH — Copernicus Open Access Hub;

CDSE — Copernicus Data Space Ecosystem;

RGBN — канали Red, Green, Blue та Near Infrared;

Python — високорівнева мова програмування;

Sentinel – 2 — супутникова місія Європейського Союзу.

ВСТУП

Актуальність роботи. Нині карта безхмарного покриття Землі є важливим елементом в регіональній та глобальній системах, які відстежують зміни територій, спричинені природними та техногенними факторами.

Наприклад, оцінка шкоди, заподіяної лісовими пожежами, спричиненими вирубкою лісів, виверження вулканів, повеней або дослідження в агрокультури, це насамперед моніторинг територій, сівозміни та інше. Для цього саме й потрібно мати безхмарний композит, щоб провести дослідження. Також такі дані будуть корисними для багатьох картографічних веб сервісів, для яких важливо мати саме останні знімки потрібних областей. Безхмарними знімками можуть цікавитись уряди країн, наприклад для відстеження лісового покриву чи виявлення інших об'єктів.

Є також інші області де потрібні такі дані, це перевезення, виробництво, лісництво, наука.

Оскільки якість знімків Землі з кожним поколінням супутників стає все більш кращою, то в майбутньому це дасть ще кращий результат розробленого алгоритму з вилучення хмар.

Мета і завдання дослідження.

Об'єкт дослідження — супутникові дані Sentinel-2. У вихідній версії роботи використано Copernicus Open Access Hub, який нині замінено Copernicus Data Space Ecosystem [11, 16].

Предмет дослідження — морфологічний оператор розширення, регресійні методи машинного навчання.

Головною метою роботи стала побудова моделі, за допомогою якої буде здійснюватись якісне вилучення хмарних пікселів із супутникових знімків з певної області України.

Завдання дослідження:

- 1) ознайомитись з можливостями Open Data Cube;
- 2) вивчити та проаналізувати вхідні дані, а саме знімки та маски хмарності;

- 3) зробити аналіз алгоритмів машинного навчання для відновлення супутникових даних;
- 4) побудувати модель вилучення хмар;
- 5) прибрати візуальну різницю в кольорах між сусідніми областями супутникових знімків;
- 6) зробити оцінку точності.

Наукова новизна одержаних результатів.

Було модернізовано маску хмарності, побудована власна модель вилучення хмарних пікселів та зроблене відновлення супутникових даних.

Практичне значення одержаних результатів.

Практична значущість цієї роботи є досить високою, оскільки існує потреба організацій та приватних осіб у якісних безхмарних зображеннях територій.

Цільовою аудиторією, для якої буде корисною ця технологія, є:

- 1) **вебсервіси**, що працюють із географічними та супутниковими даними (наприклад, сервіси моніторингу рослинного покриву);
- 2) **агропромисловий сектор**, якому необхідні дані для дослідження стану сільськогосподарських угідь;
- 3) **підприємства лісового господарства**, які можуть використовувати дані для визначення зон насадження нових дерев та загального моніторингу лісових масивів;
- 4) **державні органи**, що мають потребу в моніторингу й аналізі міських територій (наприклад, для відстеження урбанізації та розбудови районів підрозділами інфраструктури). Крім того, Міністерству внутрішніх справ такі дані будуть корисні для виявлення осередків незаконного видобутку бурштину;
- 5) **міжнародні організації**, які займаються глобальними екологічними проблемами, зокрема скупченням сміття в океанах або таненням льодовиків. Безхмарні знімки допоможуть аналізувати динаміку цих процесів;
- 6) **водні та комунальні служби**, які зможуть забезпечувати збалансоване управління водними ресурсами конкретного регіону.

1 СУЧАСНИЙ СТАН ЗАДАЧІ ПОБУДОВИ БЕЗХМАРНИХ ЗНІМКІВ

Отримання безхмарних супутникових знімків відіграє ключову роль в аналізі та моніторингу Землі. Для проведення власного дослідження вкрай важливо мати якісні та належним чином оброблені дані. Щоб зрозуміти, навіщо розвивати цю технологію, необхідно проаналізувати її поточний стан.


На сьогодні одними з найвідоміших компаній у сфері супутникового моніторингу Землі, які мають власні аналоги алгоритмів вилучення хмар із супутникових знімків, є американська Descartes Labs та австралійська EOxCloudless. У зв'язку з цим виникає необхідність провести огляд їхніх безхмарних карт для виявлення недоліків на зображеннях.

1.1 Descartes Labs


Descartes Labs використовує власний Python API. Для побудови безхмарних зображень компанія застосовує дані супутників Landsat 8, Sentinel-1 SAR, Sentinel-2 Red Edge, а також дані аерозйомки, які покривають лише територію США.

Під час первинного аналізу карт цієї організації виявлено дефектні смуги (рис. 1.1(б)), тобто різницю значень пікселів після склеювання. На знімках у деяких регіонах присутня велика кількість хмарних пікселів (рис. 1.1(а)), а також помітна різниця між пікселями на стиках знімків.

Таким чином, алгоритм отримання безхмарних супутникових знімків Descartes Labs має недоліки, що впливають на якість результату.



(а) Дефектні зони хмарами



(б) Склейка знімків

Рисунок 1.1 — Супутникові знімки Descartes Labs

1.2 EOxCloudless

Іншою компанією, що спеціалізується на обробці супутникових даних, є EOxCloudless. Вона аналізує дані супутників Sentinel-1 та Sentinel-2 і забезпечує моніторинг сільськогосподарських територій за допомогою оптичних і радіолокаційних даних.



(а) Дефектні зони хмарами



(б) Склейка знімків

Рисунок 1.2 — Супутникові знімки EOxCloudless

На знімках також присутні дефекти (рис. 1.2(б)), хоч і не в такій кількості, як на супутникових знімках попередньої компанії. У цьому випадку колірна різниця між регіонами (рис. 1.2(а)) помітно менша, тому зображення виглядає краще.

На основі первинного аналізу результатів EOxCloudless та Descartes Labs у деяких регіонах виявлено неякісні знімки та проблеми з відновленням неповних да-

них. Україні потрібна власна безхмарна карта, оскільки вона дасть змогу покращити моніторинг посівних площ і аналіз культур, а також відстежувати розливи водойм і річок.

У дипломній роботі описано можливе вирішення проблеми неповних даних і створено модель, яка формує безхмарний супутниковий знімок на основі даних сімейства Sentinel-2. Модель також може працювати з будь-якими триканальними RGB-супутниковими даними.

Висновки до розділу 1

Досліджено та проаналізовано сучасний стан побудови безхмарних супутникових знімків. Розглянуто приклади знімків компаній EOxCloudless та Descartes Labs, які мають власні аналоги технології вилучення хмарних пікселів. Виявлено їхні недоліки та обґрунтовано потребу у безхмарних супутникових зображеннях України.

2 ОГЛЯД OPEN DATA CUBE ТА СУПУТНИКОВИХ ДАНИХ

Open Data Cube — це програмна платформа з відкритим кодом для керування та аналізу геопросторових супутникових даних [6, 17].

Платформа дає змогу проводити різні дослідження та завантажувати необхідну інформацію, що надходить від супутників.

2.1 Open Data Cube

Основні переваги системи Data Cube:

- Каталог великих геопросторових обсягів даних;
- API на основі Python для високопродуктивних запитів;
- Надає вченим та іншим користувачам легку можливість виконувати дослідницький аналіз даних;
- Дозволяє масштабовану обробку даних континенту, що зберігається;
- Відстеження походження всіх даних, що містяться, щоб забезпечити контроль якості та оновлення.

Мета ODC — збільшити роль супутникових даних наданням відкритого та доступного дослідницького інструменту та сприяти розвитку сфери аналізу даних супутників. Це рішення має на меті підтримати ключові цілі, що включають в себе полегшення використання даних та підтримувати глобальні пріоритетні міжнародні програми. ODC повинен створити ”бренд якому користувачі можуть довіряти, і він повинен сприяти позитивному користувацькому досвіду. Це має стати можливим завдяки розробці спільноти ODC з відкритим кодом, яка активно займається розробкою, ділиться алгоритмами та надає підтримку один одному для вирішення проблем.

Як це рішення дозволяє задовольнити попит багатьох світових користувачів з обмеженими ресурсами? Масштабованість — одна з ключових проблем, з якою

стикається ODC. Хоча початкові зусилля привели лише до декількох національних масштабів впровадження Data Cube (наприклад, Австралія, Колумбія, Швейцарія), Є багато інших країн та глобальних організацій, що мають високий інтерес до ODC. Завдяки взаємодії з зацікавленими організаціями та поточними користувачами, очікується, що кількість ODC збільшиться і спільнота ODC процвітатиме з розширенням своїх можливостей.

Ядро ODC служить прошарком між супутниковими постачальниками даних та додатками. Існує набір інструментів з відкритим кодом, щоб допомогти вченим проводити дослідження, використовуючи дані, якими керує ODC. Популярні інструменти, що використовуються у спільноті, яка використовує ODC Core як основу, включають:

- **Командний рядок** інструмент, який використовують програмісти / розробники для взаємодії з ODC;
- **Відкритий ODC Візуальний** та інтерактивний веб-додаток, який дозволяє користувачам досліджувати свій інвентар наявних даних;
- **ODC статистика** Оптимізований засіб проведення розширеного аналізу в системі ODC. Цей інструмент орієнтований на вчених;
- **Веб-інтерфейс ODC**: веб-додаток, який дозволяє розробникам інтерактивно демонструвати та візуалізувати вихід алгоритмів;
- **Jupyter Notebook** Такі файли дають інтерактивну можливість візуалізувати аналізовані дані;
- **Веб-сервіси** відкритого геопросторового консорціуму: адаптери, які можуть підключати додатки non-ODC до ODC

Усі вищеописані інструменти формують користувацьку структуру управління Open Data Cube.

У роботі був використаний ODC, який керується Інститутом космічних досліджень НАН України та ДКА України.

Причина використання ODC

Причиною використання ODC у роботі стала розвиваюча спільнота, легкість

та швидкість завантаження знімків супутника родини Sentinel-2 і прикладні програми обробки з використанням мови програмування Python, за допомогою яких відбувалось композитування, візуалізація. Але найбільша перевага ODC є масштабованість даних, що означає можливість завантажувати і опрацьовувати як завгодно великі території.

2.2 Супутник Sentinel-2

У цій роботі використано дані космічної місії Sentinel-2 [1, 2], що дають композити у багатьох каналах.

Композит — це сукупність каналів, які використовуються для візуалізації зображення.

Перший супутник Sentinel-2A цієї місії запущено у 2015 році, а другий, Sentinel-2B, — у 2016 році. Супутники отримують дані (таб. 2.1) з просторовою роздільністю 10, 20 та 60 м у 13 спектральних каналах [16]. Частота знімання на екваторі становить приблизно п'ять днів [16].

Таблиця 2.1 — Класифікація каналів композиту супутників Sentinel-2

Номер каналу	Назва каналу
1	Coastal aerosol
2	Blue
3	Green
4	Red
5, 6, 7	Vegetation red edge
8	NIR
8A	Narrow NIR
9	Water vapour
10	SWIR – Cirrus
11, 12	SWIR

Таким чином, сімейство супутників Sentinel-2 надає достатньо інформації для досліджень у сфері аналізу супутникових даних і моніторингу земного покриву.

Висновки до розділу 2

Отже, Open Data Cube — це програмна платформа з відкритим кодом і спільнота, що розвивають можливості аналізу супутникових даних [6, 17]. У вихідному дослідженні супутникові дані та маски хмарності надходили з Copernicus Open Access Hub (COAH). Нині цей сервіс замінено платформою Copernicus Data Space Ecosystem (CDSE), тому для нових досліджень слід використовувати актуальні інструменти CDSE [11, 16].

3 УТОЧНЕННЯ МАСКИ ХМАР

Точне визначення та уточнення маски хмарності є критично важливим етапом попередньої обробки супутникових даних. Оскільки хмари, тіні та серпанок викривляють спектральні характеристики відкритої поверхні, їх неповне вилучення призводить до появи артефактів та помилок у фінальних супутникових композитах.

3.1 Маска хмарності

Маска хмарності є растровим шаром, у якому кожному пікселю відповідає клас поверхні або атмосферного явища.

Разом з композитами сервіс СОАН надає також і маску хмарності. Вона є масивом із розмірністю, що співпадає з розмірністю самого знімку, де кожен піксель має значення від 0 до 11 (таб. 3.1). Це певний класифікатор, де цифра позначає область знімка, наприклад хмари, рослинність чи перисті хмари. Відповідно ми можемо одержати інформацію про кожний піксель композиту, а саме чи є він захмарений чи ні.

Таблиця 3.1 — Класи маски хмарності

Значення	Клас
1	Немає інформації
2	Дефектні об'єкти
3	Область темних пікселів
4	Тінь хмар
5	Рослинність
6	Не рослинність
7	Вода
8	Хмара середньої прозорості
9	Не прозорі хмари
10	Прозорі хмари
11	Сніг

У досліджуваних даних використано значення, що позначають чисту поверхню, хмари, тіні хмар і серпанок. Для побудови бінарної маски хмарними вважалися класи 2, 3, 8 і 9, а окремо оброблявся клас серпанку.

3.2 Недоліки маски хмар від COAN

На жаль, дані що дає *corernicus hub*, не є ідеальними, саме це стосується і маски хмар. Після написання алгоритму було проведено перші його тестування, результат був неякісним.

Було проведено дослідження чому це відбувається, і виявилось, що не до всіх знімків класифікатор для маски надається в тому ж самому розрізненні що і відповідний йому 4 каналний композит. Дана проблема потребувала вирішення як і для покращення оригінальної маски так і для алгоритму вилучення хмар.




Рисунок 3.1 — Оригінальна маска хмарності від СОАН

На завантажених файлах супутникових знімків із розрізненням 10 м була виявлена маска із розрізненням 20, що й приводило до проблеми того, що реальні хмари на композиті не покривались класифікатором (рис. 3.1).

3.3 Розширення маски хмар

Для уточнення маски хмар був використаний алгоритм Dilation.

Розширення (Dilation) - один з двох основних операторів математичної морфології, інший - ерозія. Зазвичай він застосовується до двійкових зображень, але є версії, які працюють на зображеннях grayscale зображень. Основний ефект оператора на бінарне зображення полягає в поступовому збільшенні меж областей пікселів

переднього плану. Таким чином, ділянки пікселів переднього плану збільшуються в розмірі, тоді як отвори в цих регіонах стають меншими.

Розширення бінарної множини A структурним елементом B визначають як

$$A \oplus B = \{s \mid \hat{B}_s \cap A \neq \emptyset\}. \quad (1)$$

Якщо зображення це $f(x)$, а структурний елемент $b(x)$, тоді розширення f на b визначається формулою 2:

$$(f \oplus b)(x) = \sup_{y \in E} [f(y) + b(x - y)] \quad (2)$$

При використанні великих структурних елементів $b(x)$ формується за формулою 3:

$$b(x) = \begin{cases} 0, & x \in B, \\ -\infty, & \text{інакше} \end{cases} \quad (3)$$

де B є підмножиною $\mathbb{R} \cup \{-\infty, +\infty\}$

У такому випадку розширення будується за формулою 4:

$$(f \oplus b)(x) = \sup_{z \in E} [f(x - z) + b(z)] = \sup_{z \in B} [f(x - z)] \quad (4)$$



Рисунок 3.2 — Приклад застосування оператора розширення

Сам процес розширення (рис. 3.2) є не складним: нехай є певна множина, яка потребує збільшення або розширення, тоді існує ще одна множина, яка виступає у ролі структурного елемента. Тоді структурний елемент проходиться по межах розширюючої множини і збільшує її границі на заданий розмір. Таким чином, ми одержуємо множину, що має ту ж саму форму, що й оригінальна, але вже збільшена.

Розглянемо приклад застосування оператора розширення у випадку супутникових даних, а саме окремого композиту та його маски.

З цього знімка (рис. 3.3) був зроблений композит та взята його маска (рис. 3.4(а)). З маски було витягнуто окремі пікселі, що відповідають окремо за перисті хмари та самі хмари. Тобто взято 10 та 2,3,8,9 значення пікселів відповідно та розширено (рис. 3.4(б)) за допомогою оператора.




Рисунок 3.3 — Знімок зроблений 2019-06-07 розміром 2000x2000



(а) Маска хмар



(б) Розширена маска хмар

Рисунок 3.4 — Маски хмар до та після розширення

Висновки до розділу 3

Уточнення маски збільшує область потенційно хмарних пікселів і зменшує ризик залишити хмари у фінальному композиті. Водночас розширення може видалити частину чистих пікселів, тому його параметри слід перевіряти на еталонній масці.

4 АЛГОРИТМ ВИЛУЧЕННЯ ХМАРНИХ ПІКСЕЛІВ

Для аналізу та тестування алгоритму брались дані за червень 2019 року Київської області. З ними був проведений глибокий аналіз на відповідність та можливість подальшої обробки, оскільки якщо в одній серії за місяць будуть знімки де хмарність складає більше 50 виході алгоритму буде композит, в якого багато пікселів матимуть чорний колір.

Тобто постала проблема відбору даних, що більш-менш підходять під реалізацію методу. Також цей процес потрібно було повністю автоматизувати, оскільки не зручно власноруч шукати потрібні знімки.

Дана проблема була вирішена за допомогою саме застосування Open Data Cube. ODC надав змогу автоматично та швидко завантажувати дані просто увівши параметри часу, широти, висоти та супутника.

Було написано процедури, які давали відсоток хмарності, що покращило обробку і тим самим відкидались знімки за той час де відсоток хмарності перевищував 35

4.1 Побудова безхмарного композиту

Спочатку всі датасети, що були завантажені потрібно очистити від знімків, кожен канал яких мав значення nan, тобто це просто зображення чорного кольору.

Потім було прийнято рішення про сортування композитів по проценту хмарності, інія та неповних знімків. Даний функціонал був доданий в ODC. Неповний знімок, це такий самий по розмірності знімок, що і інші в датасеті, але не відображена вся територія. Таким чином відбирались такі дані де відсоток загальної хмарності був не більшим за 35-40 відсотків, оскільки, інакше вихідний знімок після роботи алгоритму буде з дефектами.

На вхід алгоритму, що прибирає хмари подається множина індексів часу та сам датасет, звідки ці знімки. Тут, вже ці знімки пройшли повний препроцесинг і

готові для обробки. Дана процедура (рис. 4.1) повинна повернути певну кількість композитів, які потім будуть оброблятися за допомогою медіани.

Для того щоб проводити вищенаведені операції з великим датасетом, у якого більше ніж два знімки, було розроблено декілька способів обробки. А саме, наступні.

Нехай в якості вхідного використовується датасет, в якому знімки проіндексовані наступним чином: [1,2,3,4,5,6....]. Тоді для побудови безхмарного композиту використано наступні методи комбінування знімків:

- 1) **Кожний з кожним** Даний алгоритм полягає у комбінуванні кожний з кожним, тобто [1.2],[2.1], але не сам з собою.

В результаті можна отримати якісне зображення, але з суттєвими затратами комп'ютерних ресурсів. На виході буде $n^2 - n$ композитів, при n вхідних знімків;

- 2) **Почергова трійка** На вхід моделі подається почергова трійка, де перший знімок буде базовим

Приклад; [1,2,3], [2,3,4], [3,4,5]

Даний метод дає оптимальну якість і є більш ощадливим до обчислювальних ресурсів.

Було досліджено швидкодію (рис. 4.2) кожного з описаних методів комбінування.

З урахуванням отриманих результатів експериментів має сенс надалі використовувати метод парами кожний з кожним при відносно малій кількості знімків і почерговою трійкою, якщо нас цікавить збереження обчислювальних ресурсів чи часу.

Вихідний знімок був побудований за допомогою метода кожний з кожним.

Для майбутнього покращення якості та швидкості опрацювання великих датасетів було розглянуто наступні методи комбінування знімків:

- 1) **Кожний базовий** На вхід подаються списки виду [1,2,3,4,..], [2,1,3,4,..], [3,1,2,4,..],

Тобто завжди подається весь датасет, причому перший знімок є базовим, а на

наступному кроці попередній базовий міняється місцями з наступним.

- 2) **Пріоритетність** Спочатку робиться сортування знімків по хмарності у датасеті.

Нехай є впорядковані знімки [3,2,5,7,6,4,1], тоді 3-ій є базовим. Наступні ітерації будуть побудовані таким чином:

3,2,5,7,6,4

3,5,7,6,4

3,7,6,4

3,4

Цей метод буде працювати виключно якщо базовий знімок з дуже малим відсотком хмарності.

Для досягнення найкращої якості вихідного композиту потрібно брати знімки, які є максимально близькими за часом зйомки. Це забезпечить менший перепад у відтінках пікселів. Таким чином після комбінування знімків і заміни захмарених пікселів, маємо кінцевий масив наступного вигляду.




Рисунок 4.1 — Схема вилучення хмарних пікселів




Рисунок 4.2 — Графік залежності часу від кількості знімків для двох методів

4.2 Медіана за каналами

Щоб отримати цілий єдиний знімок з мінімальним за кількістю захмарених пікселів, було використано медіану. Дана процедура на вхід отримує кілька знімків (рис. 4.3) та проходить по кожному каналу кожного знімка, тим самим формуючи єдине число, а саме піксель окремого каналу. Причому дана медіана не чіпає пікселі, які не містять ніякої інформації (NODATA).

Таким чином створюється масив (4,x,y) (рис. 4.4), де x, y - розмірність вхідних знімків, 4- це канали Red, Green, Blue та Nir.




Рисунок 4.3 — Вихідний набір даних для побудови композиту (частина Київської області, знімки з '2019-05-31' по '2019-06-30')




Рисунок 4.4 — Графік залежності часу від кількості знімків для двох методів

Висновки до розділу 4

Найкращу якість покриття забезпечує метод “кожний з кожним”, тоді як метод ковзного вікна є компромісом між якістю та швидкістю. Для подальших експериментів доцільно застосувати паралельну обробку пар знімків.

5 МОДЕЛЬ ВІДНОВЛЕННЯ СУПУТНИКОВИХ ДАНИХ

Часто в супутникових даних зустрічаються ситуації, коли в датасеті є неповні знімки (рис. 5.1).




Рисунок 5.1 — Приклад неповних даних

На жаль, саме через такі випадки в безхмарному результуючому знімку можна помітити, що на деяких частинах зображення (рис. 5.2) можна побачити різницю між колірними просторами, а саме на одному з регіонів може бути більше зелені або навпаки менше, що буде одразу помітно на цілому зображенні.

Тому постає задача у розв’язання проблеми. Необхідно розглянути алгоритми мета яких - переведення колірного простору між зображеннями.



Рисунок 5.2 — Результат обробки алгоритмом безхмарного композитування з дефектами склейки

5.1 Color Transfer

Дан Рудерман та інші спеціалісти. розробили кольоровий простір, який називається $\alpha\beta$, що мінімізує кореляцію між каналами для багатьох природних сцен. Даний простір був зроблений на аналізі того як сприймає та обробляє вхідну інформацію зорова система людини природні сцени. Автори представили новий формат $\alpha\beta$ беручи за основу зорову систему людини.

Між осями у просторі $\alpha\beta$ є вирази, що дозволяють нам використовувати різні дії в різних каналах, при чому не переживаючи, що не з'являться дефекти на зображенні. Плюс - цей колірний простір логарифмічний, що значить нормальне масштабування.

Даний алгоритм досі не розглядався у контексті роботи із супутниковими знімками. Тому є необхідність зробити певний аналіз щодо того чи слід його використовувати між сусідніми регіонами, оскільки до цього його застосовували тільки для звичайних RGB зображень.

Було запрограмовано вищеописаний алгоритм та виявлено такі факти:

- 1) **Не було знайдено методу, що переводить Geotiff знімок у формат LAB**
Проблема полягає в тому, що оригінальний алгоритм перенесення кольору загалом працює із зображеннями з малим масштабом, а саме наприклад значення $[0 - 255]$. У знімках формату Geotiff діапазон набагато більший $[0 - 10\,000]$;
- 2) **Метод не може забезпечити правильну відповідність територій** Тут має-ться на увазі, що якщо на зображенні на яке ми хочемо накласти новий колірний простір є регіон, наприклад лісів чи полів, то після обробки ті ж самі регіони мають і залишитись лісами чи полем..

Провівши аналіз алгоритму перенесення колірного простору, було прийнято рішення щодо застосування методів машинного навчання, адже саме завдяки ним можна одержати правильне зображення де у відповідності зі знімком з якого беруть

колір на знімку до якого його застосували будуть максимально наближені регіони по своїй притаманності, тобто якщо було озеленене поле воно стане більш сухим і світлим, якщо такі були наявні у знімку з якого брали стиль.

Коли мова йде про обробку супутникових зображень і щоб на виході отримувати не класифікатор, а значення пікселів, то загалом використовують регресійні методи машинного навчання.

До найбільш придатних алгоритмів які вміють працювати зі знімками відносять лінійну, поліноміальну, баєсову регресію, регресію в методі опорних векторів та відомий багат шаровий перцептрон і алгоритм випадкового лісу. Вважаючи доцільним їх застосування у даній роботі, потрібно зробити їхній огляд.

5.2 Лінійна регресія

У математичній статистиці лінійна регресія — це метод побудови залежності між змінною y та векторною залежною змінною X .

При використанні даного алгоритму машинного навчання взаємозв'язок між даними будується, використовуючи лінійні функції, при чому невідомі параметри функції отримуються за вхідними даними. Так само як і інші регресійні моделі лінійна регресія повертає розподіл умовної ймовірності y в залежності від X .

Для знаходження параметрів лінійної регресії загалом використовується метод найменших квадратів (МНК). Також існує можливість використання методу найменших квадратів для нелінійних моделей.

Якщо говорити мовою формул (5):

$$y = f(x, b) + \varepsilon, \quad E(\varepsilon) = 0 \quad (5)$$

де b — параметри моделі, ε — випадкова похибка моделі.

називається лінійною регресією, якщо $f(x, b)$ подається у вигляді (6):

$$f(x, b) = b_1x_1 + b_2x_2 + \dots + b_kx_k = \sum_{j=1}^k b_jx_j = x^T \quad (6)$$

b_j — параметри регресії, x_j — регресори, k — кількість факторів у моделі

Також виділяють і так звану множинну регресію, що подається у вигляді (7):

$$Y = b_0 + b_1x_{i1} + \dots + b_jx_{ij} + \dots + b_kx_{ik} + e_i \quad (7)$$

Вищеописане звісно є частковим випадком того, що можна визначити за кількості вимірювань, щоб однозначно визначити якого вигляду набуває параметр β .

Використовуючи саме алгоритм баєсівської регресії існує можливість отримання ще додаткової інформації, а саме апіорної ймовірності розподілу. Дані ймовірності сильно взаємопов'язані із функцією правдоподібності даних відповідно до теореми Баєса для отримання вже апостеріорних ймовірностей важливих параметрів β та σ^2 .

Дані ймовірності дуже залежать від кількості та якості інформації, що подається на вхід базової моделі, оскільки функція лінійна.

Щодо версії алгоритму машинного навчання, яка застосовувалась у роботі, то це Bayesian ridge, що використовує регуляризацію з нормою L2, тоді як класична баєсова регресія - це регресійна модель, визначена з явними апіорними ймовірностями та параметрами. Вибір ймовірностей може мати ефект регуляризації, наприклад. використання розподілу Лапласа для коефіцієнтів еквівалентно регуляризації L1. Вони не однакові, тому що Bayesian ridge є своєрідною моделлю регресії, а баєсівський підхід є загальним способом визначення та оцінки статистичних моделей.

5.3 Баєсова регресія

У баєсовій моделі коефіцієнти трактуються як випадкові величини з апіорним розподілом. Після спостереження навчальних даних отримується апостеріорний розподіл, математичне сподівання якого використовується для прогнозування кольору цільового регіону.

У даному алгоритмі машинного навчання лежить в основі вищеописана лінійна регресія. Тут так само визначена регресійна модель (8):

$$y_i = \alpha + \beta x_i + \varepsilon_i, \quad i = 1, \dots, n. \quad (8)$$

Тут ε_i — незалежні та нормально розподілені випадкові величини з нульовим середнім та дисперсією σ^2 .

Визначимо функцію максимальної правдоподібності (9):

$$\rho(y \mid X, \beta, \sigma^2) = (\sigma^2)^{-\frac{n}{2}} \exp \left(-\frac{1}{2\sigma^2} (y - X\beta)^T (y - X\beta) \right) \quad (9)$$

Для того, щоб знайти розв'язок (10) за допомогою відомого методу найменших квадратів використовують псевдообернення Мура-Пенроуза:

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad (10)$$

де X — матриця із розмірністю $n \times k$, причому кожен із рядків представлений у вигляді x_i^T , а y є вектором $[y_1, y_2, \dots, y_n]^T$.

5.5 Багатошаровий перцептрон

Одним із найкращих по якості алгоритмом машинного навчання є багатошаровий перцептрон. У багатошаровому перцептроні існує можливість використання більше ніж одного лінійного шару (рис. 5.3). Розглянемо на прикладі звичайну тришарову нейронну мережу перцептрону, тоді перший шар називається вхідним, середній шар має назву прихований, що і є головною відмінністю від перцептрону Розенблата. І останній шар відповідно вихідний.

Спочатку йде подача інформації до вхідного шару і на виході отримуємо результат моделі. У даній мережі звісно можна збільшувати кількість прихованих шарів нейронів, що в результаті дасть якісніший результат, але при цьому сильно зросте використання обчислювальних ресурсів. Тому дуже важливо правильно вміти налаштовувати так звані ‘гіпер параметри’, від яких залежить швидкість та якість обробки.




Рисунок 5.3 — Приклад багатошарового перцептрону

Одними із ключовими характеристиками багатошаровому перцептроні є використання нелінійної функції активації, як правило сигмоїдної. Також у ньому як вже було сказано число шарів, які навчають, більше одного. У загальних випадках використовують не більше трьох.

Сигнали, що одержує модель можуть бути інтерпретовані у десяткових чи-

слах. Після цього бажано провести нормалізацію даних значень. Це потрібно робити, оскільки функція активації є сигмоїдальною і приймає значення від 0 до 1.

Навчання багатошарового перцептрону проводиться до стабілізації коефіцієнтів при навчанні або зупиняється не дійшовши кінця навчання, щоб уникнути перенавчання.

5.6 Випадковий ліс

Алгоритм машинного навчання, який називається випадковий ліс - це своєрідний оцінювач, який підходить до ряду класифікуючих дерев рішень на різних гілках набору даних і використовує усереднення для підвищення точності прогнозування та контролю над вхідною інформацією.

В основі алгоритм випадкового лісу (рис. 5.4) лежать так звані дерева рішень, за допомогою яких відбувається обробка вхідної інформації. У машинному навчанні дерева рішень - це певний метод для обчислення значень та параметрів моделі у прогнозуванні. Дану назву вони отримали, тому що прийняття та вихідний результат будується по гілках, таким чином створюється ніби дерево де кожна гілка відповідає на питання "якщо ... тоді ... подібно до гілок дерева.

Якщо ми уявимо, що ми почнемо з певної вибірки, для якої ми хочемо передбачити клас чи побудувати регресійну модель, то потрібно починати з низу гілки і йти по рішенням вгору, щоб отримати відповідь, поки не дійдемо до першої розгалуженої гілки. Це розгалуження можна вважати як особливість даного методу машинного навчання, і питання в тому де вона з'явиться. Тепер йде послідовне прийняття рішень, щодо того чи йти далі чи обрати іншу гілку для обробки рішень. Це відбувається до тих пір поки не приймається рішення про перехід на наступну гілку, або повторити процес знову, тим самим покращити результати. Ця кінцева точка називається аркушем, і в деревах рішень представлений кінцевий результат: передбачуваний клас або значення.




Рисунок 5.4 — Пример ансамбля деревьев

Висновки до розділу 5

Була описана проблема, що з'являється у випадку використання неповних супутникових знімків, як вхідних даних у модель, що дає безхмарний супутниковий знімок. Зроблений огляд відомого алгоритму color transfer перенесення кольорового стилю та описані його недоліки для застосування супутникових знімків. Було оглянуто алгоритми машинного навчання як можливе розв'язання проблеми відновлення супутникових даних.

6 ОЦІНКА ТОЧНОСТІ МАСКИ ХМАР ТА КОМПОЗИТИНГУ

Для впевненості у вирішенні проблеми уточнення маски хмарності, було проведено дослідження та зроблена оцінка точності. Для цього знову був взятий знімок (рис. 6.1) частини Київської області та побудовано власноруч реальну маску хмар.




Рисунок 6.1 — Область для оцінки точності

Для демонстрації була взята маска верхнього лівого квадрата 500x500 (рис.6.2).




Рисунок 6.2 — Еталонна маска

6.1 Результати покращення маски хмар




Рисунок 6.3 — Приклад уточнення маски хмар

Таблиця 6.1 — Порівняння характеристик масок хмар

Метрика	СОАН	Еталонна	Уточнена
Частка хмар у масці	0,19%	0,22%	0,21%
Покриття відносно еталонної маски	$\approx 8\%$	100%	$\approx 95\%$

Таблиця 6.2 — Оцінювання точності уточнення маски хмар

Метрика	COAH	Уточнена маска
Кореляція Пірсона	0,89	0,93
Кореляція Спірмена	0,89	0,93
Тау Кендалла	0,89	0,93
Індекс Жаккара	0,83	0,89
Евклідова відстань	390,61	302,98
Мангеттенська відстань	152579	91797

Уточнена маска має вищу кореляцію з еталонною маскою і менші відстані. Отже, морфологічне розширення краще враховує периферію хмар.

Висновки до розділу 6

Зроблено оцінку точності оператору розширення. Для цього побудовано еталонну маску і протестовано метриками на схожість даних. Виявлено, що коефіцієнт кореляції пірсона та спірмена збільшеної маски підвищується на 5% і складає приблизно 94%, а маски хмар від СОАН 89%.

7 РЕЗУЛЬТАТИ РЕГРЕСІЙНИХ МОДЕЛЕЙ

7.1 Навчальні дані

За навчальні дані (рис. 7.1) було взято територію з координатами. Був зроблений єдиний безхмарний композит, та взято перший знімок місяця і зроблене тестове зображення шляхом поділу на половину.




Рисунок 7.1 — Знімок навчальних даних

Таким чином, маємо знімок в якого ліва частина являє собою джерело кольорового простору, а права - ціл्लю на який потрібно його перевести.

Дані що були вибрані для тренування алгоритмів машинного навчання були взяті на стику лівого і правого знімків, а саме так щоб вони між собою перетинались, що дозволить зменшити контраст саме між сусідніми регіонами знімків, тоді саме зображення матиме більш природній колір і не буде сильного контрасту.

Варто зауважити, що якість вихідного знімку сильно залежить від того який великий перетин навчальних даних береться, оскільки якщо взяти доволі малий, то

більш ймовірно результат не сильно буде відрізнятись від оригінального знімка, тому у навчанні алгоритмів брались 70 відсотків області одного знімка і 30 області іншого. Це дало оптимальний результат на виході регресійних моделей, які застосовувались у вирішенні даної проблеми.

NDVI

NDVI (Normalized Difference Vegetation Index) - нормалізований відносний показник кількості фотосинтетичних активних біомас (зазвичай називають вегетаційним індексом). Цей індекс будується за відбиттям від рослин променів, що містять інфрачервоні спектри зонів. Значення індекса лежать в діапазоні від 0,20 до 0,95. Чим зеленіший регіон для дослідження в час вегетації, тим більше значення індексу NDVI. Таким чином, NDVI - це індекс, за яким можна робити висновки про розвиток зеленої зони на супутникових знімках.

Найбільш поширене використання NDVI - оцінка росту культур. По карті NDVI можна дати оцінку території, а саме побачити як добре сходять врожай та відслідковувати посуху. Для візуальної оцінки даного індексу користуються кольоровою шкалою: якщо значення менше 0.25, то регіон матиме сірий колір. Відповідно якщо значення вище, то говорять про середній чи нормальний розвиток тієї чи іншої культури. Результуючу інформацію потрібно вміти аналізувати, оскільки культури сходять по різному і на різних часових проміжках.

У даній роботі індекс NDVI застосовується як фактор, що покращує якість регресивних моделей так і елемент для оцінки точності застосування того чи іншого алгоритму. Тому перед дослідження до звичайного 4 каналного композиту додається ще один, а саме NDVI. Це хоч і вплинуло на швидкість обробки методів машинного навчання, але покращило якість результуючого знімку.

$$NDVI = (Blue - Red) / (Blue + Red), \quad (12)$$

де Blue - синій, Red- червоний канали.

Intensity

Також для підвищення точності був доданий 6-ий канал світлості знімка, що обчислюється за формулою:

$$I = (0.42 * Blue + 0.98 * Green + 0.6 * Red + NIR)/3 \quad (13)$$

7.2 Результати

Отримані в ході експериментів числові показники точності (таб. 7.1) та результуючі зображення дозволяють провести детальний порівняльний аналіз алгоритмів за ступенем їх придатності до задачі перенесення колірного простору між супутниковими знімками.

Для оцінки якості моделювання було використано шість стандартних метрик регресії: коефіцієнт детермінації (R^2), частку поясненої дисперсії (*Explained Variance Score*), максимальну похибку (*Max Error*), середня абсолютну похибку (*MAE*), середньоквадратичну похибку (*MSE*) та медіанну абсолютну похибку (*Median AE*).

Таблиця 7.1 — Порівняльна оцінка точності алгоритмів регресії та машинного навчання

Метрика точності	Лінійна	Поліном.	Баєсова	Випадковий ліс	MLP
Explained variance	$-2,26 \cdot 10^{23}$	$-1,69 \cdot 10^{22}$	-0,18	0,76	0,81
Max error	$1,62 \cdot 10^{16}$	$1,03 \cdot 10^{17}$	6532,00	4143,13	3334,50
Mean absolute error	$2,52 \cdot 10^{14}$	$5,36 \cdot 10^{11}$	638,81	385,0	343,77
Mean squared error	$2,02 \cdot 10^{29}$	$1,51 \cdot 10^{28}$	$1,31 \cdot 10^6$	368,11	178,39
Median abs. error	$1,22 \cdot 10^{14}$	$2,35 \cdot 10^6$	183,60	102,20	64,83
R2 score	$-2,26 \cdot 10^{23}$	$-1,69 \cdot 10^{22}$	-0,46	0,67	0,72

7.2.1 Лінійна та Поліноміальна регресії

Первинне тестування базових математичних моделей виявило їхню повну непридатність для розв’язання поставленої задачі (рис. 7.2).




Рисунок 7.2 — Демонстрація роботи лінійної та поліноміальної регресій

- **Лінійна регресія** показала критично незадовільні результати. Показники R^2 та *Explained Variance* набули аномальних від’ємних значень порядку $-2,26 \cdot 10^{23}$, що свідчить про повну неадекватність моделі — її передбачення виявилися значно гіршими, ніж банальне усереднення цільових значень. Середньоквадратична похибка ($MSE \approx 2,02 \cdot 10^{29}$) та середня абсолютна похибка ($MAE \approx 2,52 \cdot 10^{14}$) підтверджують наявність катастрофічних відхилень у спектральних

каналах. Причиною цього є надмірна спрощеність лінійної моделі: залежність кольірних спектрів супутникових знімків має складний нелінійний характер, який неможливо описати простим лінійним перетворенням.

- **Поліноміальна регресія** (з максимально можливим ступенем полінома $n = 6$, обмеженим наявними обчислювальними ресурсами) продемонструвала деяке покращення порівняно з лінійною. Зорієнтовані метрики похибок знизилися на кілька порядків (наприклад, MAE впала до $5,36 \cdot 10^{11}$, а MSE — до $1,51 \cdot 10^{28}$). Проте коефіцієнт детермінації ($R^2 \approx -1,69 \cdot 10^{22}$) залишається глибоко у від'ємній зоні, а максимальна похибка (Max Error $\approx 1,03 \cdot 10^{17}$) навіть зросла порівняно з лінійним наближенням. Це пояснюється явищем прокляття розмірності та явищем перенавчання (оверфітінгу) поліномів високого степеня на межах діапазонів значень пікселів. Візуально знімки після такої обробки містять суттєві спотворення кольорів та артефакти.

7.2.2 Баєсова регресія

Застосування **Баєсової регресії** стало першим кроком до виходу з зони екстремально великих похибок (рис. 7.3). Впровадження регуляризації та апріорного розподілу параметрів дозволило стабілізувати процес навчання та уникнути вибуху градієнтів/ваг.




Рисунок 7.3 — Демонстрація роботи баєсової регресії

Середня абсолютна похибка знизилася до прийнятного рівня у 638,81 умовних одиниць інтенсивності, а медіанна похибка (Median AE) склала 183,60. Значення R^2 ($-0,46$) та *Explained Variance* ($-0,18$), хоч і залишаються від'ємними, демонструють фундаментальний стрибок у якості порівняно з попередніми методами. Модель змогла згладити глобальні колірні зсуви, однак візуальний аналіз знімка свідчить про те, що локальні спектральні особливості та дрібні деталі зображення передаються некоректно. Баєсова регресія виявилася недостатньо гнучкою для адаптації до складних розподілів яскравості на неоднорідних ділянках (наприклад, межа «вода—рослинність»).

7.2.3 Ансамблеві та нейромережеві підходи

Справжній якісний прорив у точності синтезу колірного простору було досягнуто лише за допомогою алгоритмів машинного та глибокого навчання (рис. 7.4).



Рисунок 7.4 — Демонстрація роботи випадкового лісу та багатошарового перцептрону

- **Випадковий ліс (Random Forest):** Даний ансамблевий алгоритм показав високу ефективність у моделюванні складних нелінійних залежностей. Показник R^2 досяг 0,67, а частка поясненої дисперсії — 0,76. Середня абсолютна похибка (MAE) знизилася орієнтовно до 385,00, а середньоквадратична похибка (MSE) склала 368,11. Медіанна похибка скоротилася майже вдвічі порівняно з Баєсовою регресією (до 102,20).
- **Багатошаровий перцептрон (MLP):** Нейромережева модель показала **найкращий результат** серед усіх досліджуваних методик за кожною без винятку метрикою:

– $R^2 = 0,72$ та $Explained\ Variance = 0,81$, що свідчить про високу здатність

моделі пояснювати варіативність колірного простору цільового знімка.

- $MAE = 343,77$ (майже вдвічі менше, ніж у Баєсової регресії та Випадкового лісу).
- $MSE = 178,39$ (найнижче значення серед усіх моделей, що підтверджує відсутність грубих викидів).
- $Median\ AE = 64,83$, що вказує на те, що для переважної більшості пікселів похибка перенесення кольору є мінімальною та непомітною для людського ока.
- $Max\ Error = 3334,50$ (мінімальна максимальна похибка серед усіх методів).

Висновки до розділу 7

- 1) **Нелінійність задачі:** Результати чітко доводять, що задача нормалізації та перенесення кольорового простору супутникових даних є глибоко нелінійною. Класичні параметричні регресійні моделі (лінійна, поліноміальна) не здатні вловити розподіл каналів та призводять до викривлення даних.
- 2) **Перевага нейромереж:** Багатошаровий перцептрон (MLP) завдяки наявності прихованих шарів та нелінійних функцій активації найкраще адаптується до спектральних характеристик знімків. Результати обробки за допомогою MLP візуально демонструють практично ідеальний безшовний перехід між правою та лівою частинами результуючого зображення.

ВИСНОВКИ

Отже, було досліджено маски хмарності, що надаються сервісом Copernicus Open Access Hub. В якості цільової було використано територію Київської області. У процесі досліджень було виявлено, що ця маска не покриває реальну область хмар і може бути покращена. Для цього було запропоновано використати морфологічний оператор розширення.

У роботі наведено також результати порівняльного аналізу методів, за допомогою яких можна комбінувати вхідні знімки для процедури вилучення хмарних пікселів. З точки зору швидкодії найкращим виявився метод вікном розміром 3, по якості - метод кожний з кожний, який і був використаний для побудови безхмарного композиту для території Київської області.

Використання композитів з покращеною маскою хмарності дозволить підвищити якість розв'язання прикладних задач спостереження Землі.

Також побудована модель відновлення супутникових даних коли вхідні знімки є неповними. Підготовлено навчальні дані та навчено алгоритми машинного навчання. Найкращу якість та точність дає багатошаровий перцептрон, його й рекомендується використовувати як спосіб вирішення даної проблеми.

ПЕРЕЛІК ПОСИЛАНЬ

- 1 Regional Retrospective High Resolution Land Cover for Ukraine: Methodology and Results / M. Lavreniuk та ін. // 2015 IEEE International Geoscience and Remote Sensing Symposium (IGARSS). IEEE, 2015. С. 3965—3968. DOI: 10 . 1109 / IGARSS . 2015 . 7326693.
- 2 Efficiency Assessment of Multitemporal C-Band Radarsat-2 Intensity and Landsat-8 Surface Reflectance Satellite Imagery for Crop Classification / S. Skakun, N. Kussul, A. Shelestov та ін. // IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing. 2015. DOI: 10 . 1109 / JSTARS . 2015 . 2434380.
- 3 *Goyal M.* Morphological Image Processing // International Journal of Computer Science and Technology. 2011. Т. 2, № 4. С. 161—165. ISSN 0976-8491.
- 4 *Dougherty E. R.* An Introduction to Morphological Image Processing. Bellingham, WA : SPIE Optical Engineering Press, 1992. ISBN 9780819407729.
- 5 *Flood N.* Seasonal Composite Landsat TM/ETM+ Images Using the Medoid (a Multi-Dimensional Median) // Remote Sensing. 2013. Т. 5, № 12. С. 6481—6500. DOI: 10.3390/rs5126481.
- 6 Bringing Open Data Cube into Practice. 2016. URL: <https://opendatacube.readthedocs.io/en/stable/about-core-concepts/index.html> (дата звернення: 28.08.2026).
- 7 *Raschka S.* Python и машинное обучение. Москва : ДМК Пресс, 2017. ISBN 978-5-97060-553-4.
- 8 Color Transfer between Images / E. Reinhard та ін. // IEEE Computer Graphics and Applications. 2001. Т. 21, № 5. С. 34—41. DOI: 10 . 1109 / 38 . 946629. URL: <https://www.cs.tau.ac.il/~turkel/imagepapers/ColorTransfer.pdf> (дата звернення: 28.08.2026).

- 9 *Дрейнер Н., Смит Г.* Прикладной регрессионный анализ. 2-е вид. Москва : Финансы и статистика, 1986.
- 10 *Лутц М.* Изучаем Python. 4-е вид. Санкт-Петербург : Символ-Плюс, 2011.
- 11 Copernicus Data Space Ecosystem. 2026. URL: [https : / / dataspace . copernicus . eu/](https://dataspace.copernicus.eu/) (дата звернення: 28.08.2026).
- 12 Знімок з дефектними зонами Descartes Labs. URL: [https://descarteslabs . com/](https://descarteslabs.com/) (дата звернення: 28.08.2026).
- 13 Склеїлка знімків від Descartes Labs. URL: [https://descarteslabs . com/](https://descarteslabs.com/) (дата звернення: 28.08.2026).
- 14 Безхмарні знімки від EOxCloudless. URL: [https://s2maps . eu/](https://s2maps.eu/) (дата звернення: 28.08.2026).
- 15 *Imam E.* Remote Sensing and GIS Module: Colour Composite Images. URL: [https : //ergp . inflibnet . ac . in/](https://ergp.inflibnet.ac.in/) (дата звернення: 28.08.2026).
- 16 Copernicus Sentinel-2 Mission. 2026. URL: [https : //dataspace . copernicus . eu/data-collections/copernicus-sentinel-missions/sentinel-2](https://dataspace.copernicus.eu/data-collections/copernicus-sentinel-missions/sentinel-2) (дата звернення: 28.08.2026).
- 17 Open Data Cube Core Concepts. 2026. URL: [https : / / opendatacube . readthedocs . io/en/stable/about-core-concepts/index.html](https://opendatacube.readthedocs.io/en/stable/about-core-concepts/index.html) (дата звернення: 28.08.2026).